RELATÓRIO ESTUDO DE CASO: CYCLISTIC

Luis Felipe Santos Chagas

1. Resumo

A Cyclistic (empresa fictícia) é uma empresa de compartilhamento de bicicletas na cidade de Chicago. A empresa apresenta dois tipos de planos, o casual (passageiros casuais) e o anual (membros). Os analistas financeiros concluíram que os membros anuais são mais lucrativos do que os passageiros casuais e o departamento de marketing acredita que a chave para o crescimento da empresa seria maximizar o número de membros, convertendo ciclistas casuais em anuais, ao invés de criar campanhas para novos clientes.

O objetivo desta análise é criar estratégias de marketing destinadas a converter os passageiros casuais em membros. Para isso, a equipe precisa entender melhor como ambos os tipos de clientes utilizam o serviço, por que os passageiros casuais iriam querer adquirir um plano anual e qual estratégia de marketing seria adotada. Serão analisados os históricos de trajetos de bicicleta para identificar as tendências.

Para isso, inicialmente são feitas as seguintes perguntas:

- Como os membros anuais e os ciclistas casuais utilizam as bicicletas?
- Por que os passageiros casuais iriam querer adquirir planos anuais?
- Qual a estratégia de marketing poderá ser adotada para influenciar os passageiros casuais a se tornarem membros?

Essas perguntas têm o objetivo de entender os dados, além de responder o problema em questão: vale a pena investir na conversão de passageiros casuais em membros? Se sim, qual a estratégia a ser adotada?

1. Preparação dos dados

São utilizados dados históricos de trajetos para analisar e identificar as tendências. Como a Cyclistic é uma empresa fictícia, será utilizado um conjunto de dados públicos, disponibilizados pela Motivate International Inc. sob esta licença. sendo, portanto, dados válidos para o propósito do estudo de caso. Os dados são disponibilizados através deste link.

Será feita uma análise anual, iniciando em julho/2021 até o mês de junho/2022. Os dados estão disponibilizados de forma mensal, portanto devem ser mesclados para o estudo do período indicado. Essa etapa foi feita com a linguagem de programação R e é descrita no arquivo "R-Markdown_Cyclistic".

2. Processamento dos dados

Devido ao grande volume de dados, será utilizado a linguagem de programação R (IDE RStudio) para a manipulação dos dados. Após o tratamento e análises iniciais, feitos em R, será utilizado o Power BI para a visualização dos dados. Esses processos também estão documentados no script R-Markdown, disponibilizado na pasta deste estudo de caso, denominado "R-Markdown_Cyclistic".

3. Análise dos dados

Foram feitas três principais análises. A primeira em um contexto geral, considerando ambos os tipos de cliente. A segunda, uma análise individual dos membros e passageiros casuais e, por último, uma análise dos tempos dos passeios. Essas análises foram feitas no Power BI, no arquivo disponibilizado na pasta deste estudo de caso, denominado "Dashboard_estudo_de_caso_Cyclistic".

3.1. Análise geral

A análise geral mostra uma tendência de haver mais passeios nos meses de maio a setembro, representando os meses de primavera e verão do hemisfério norte. Isso pode ser visto no gráfico **Quantidade de Passeios por Mês**.

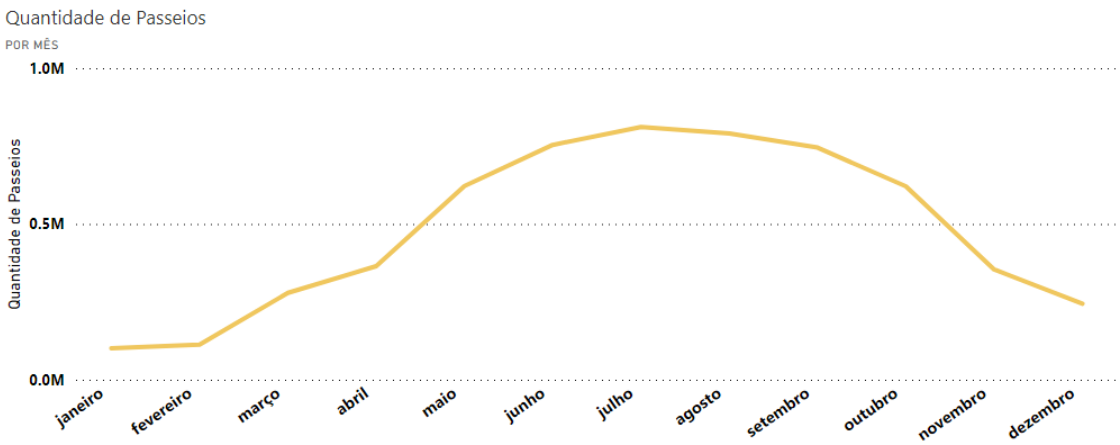

Outro ponto importante é a quantidade de passeios feitos por membros e por passageiros casuais. Como pode ser visto no gráfico **Quantidade de Passeios por Tipo de Plano**, existem mais passeios de membros, porém não há uma grande diferença, sendo cerca de 57% membros e 43% casuais. Isso pode significar que existe uma boa margem de passageiros casuais que podem ser convertidos em membros anuais.

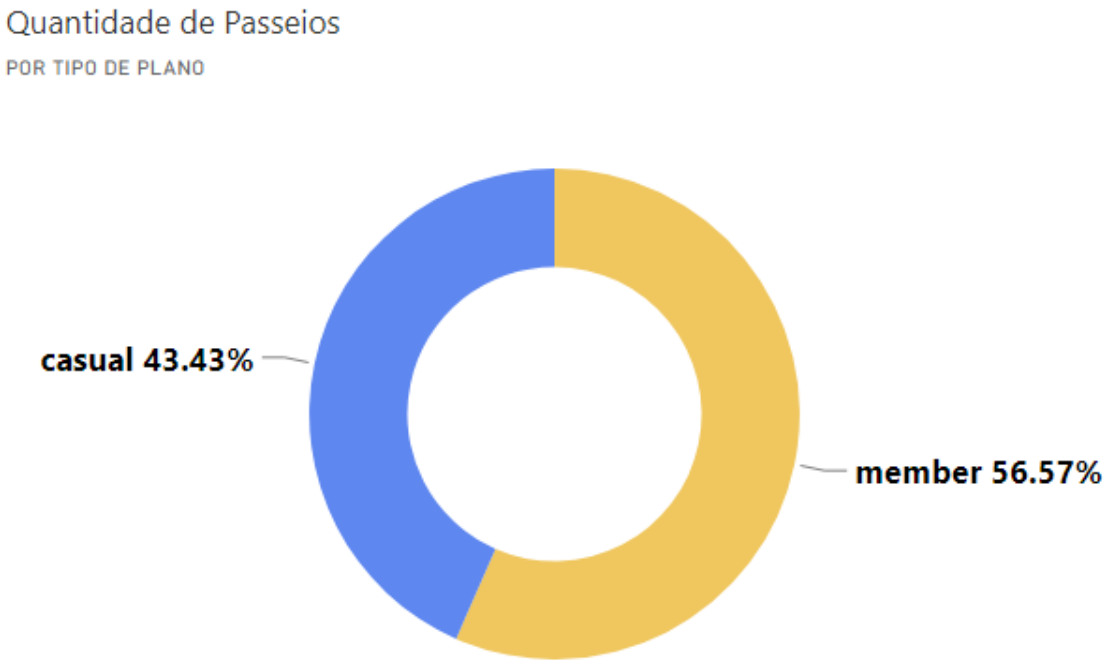

Outra análise interessante é com relação aos dias da semana. Há mais passeios no final de semana, porém, em geral, os dias são equilibrados, como pode ser observado no gráfico **Quantidade de Passeios por Dia da Semana.**

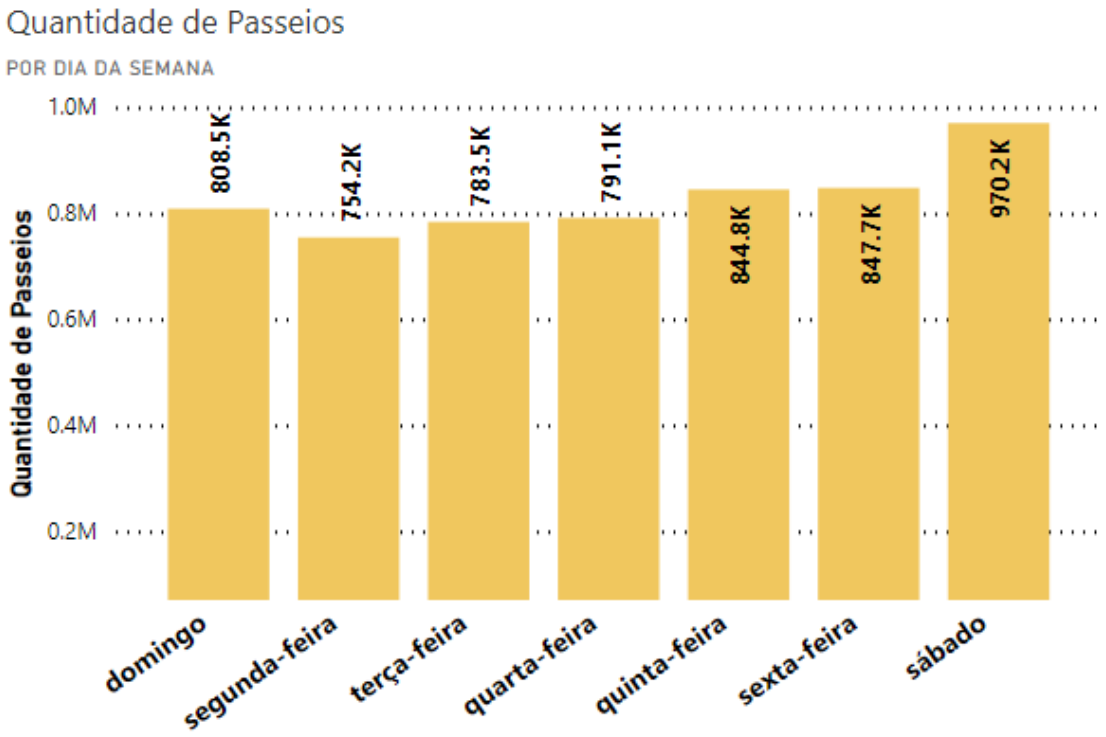

3.2. Análise por plano

Focando, agora nos membros, temos a mesma tendência na utilização das bicicletas por mês e a quantidade de passeios se concentram mais no meio da semana (segunda a sexta), uma grande parte, provavelmente, para deslocamento ao trabalho.

Já, para os casuais, há a mesma tendência de passeios por mês, com pico de utilização em julho. Outro ponto é que, apesar de haver mais passeios nos dias de fim de semana, existem muitos passeios de segunda a sexta. Isso representa passageiros casuais que possuem o mesmo padrão de utilização do serviço que os membros anuais. Essa análise pode ser observada no gráfico **Quantidade de Passeios por Dia da Semana**, filtrada para os passageiros casuais.

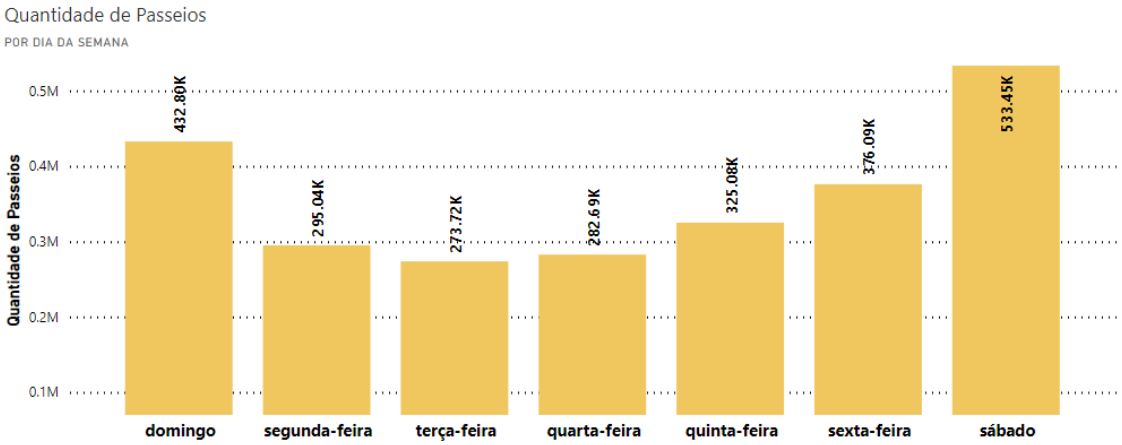

3.3. Análise por tempo de passeio

Essa análise teve como objetivo principal, comprovar que muitos passageiros casuais apresentam o mesmo padrão de utilização do serviço que os membros anuais. Nessa análise, percebe-se que, para os membros, mais de 90% dos passeios possuem tempos abaixo de 30 minutos (o que pode indicar deslocamentos casa-trabalho e vice-versa) nos dias da semana. Já, para os casuais, essa mesma análise retorna uma porcentagem de mais de 80% de passeios com menos de 30 minutos.

4. Resultados das análises

Com isso, é possível responder as perguntas inicialmente feitas:

- **Como os membros anuais e os ciclistas casuais utilizam as bicicletas?** Os membros utilizam mais de segunda a sexta, provavelmente para deslocamento ao trabalho. Já os casuais utilizam mais durante o fim de semana, porém existem muitos passageiros casuais[1] que utilizam o serviço de segunda a sexta, tendo assim, o mesmo padrão de utilização que os membro anuais.
- **Por que os passageiros casuais iriam querer adquirir planos anuais?** Como informado na pergunta acima, existe uma parcela de passageiros casuais que utilizam o serviço no meio da semana, sendo um padrão de utilização dos membros. Essas pessoas devem ser o foco das ações de marketing.
- **Qual a estratégia de marketing poderá ser adotada para influenciar os passageiros casuais a se tornarem membros?** Demonstrar, para aqueles que possuem planos casuais e utilizam o serviço de segunda a sexta que a troca para um plano anual vale a pena, focando nos benefícios em ser membro anual. Temos ainda que, como o pico de utilização dos passageiros casuais é em julho, o marketing poderia ser implementado entre os meses de junho a agosto.

5. Expandindo as descobertas

Algumas informações a mais poderiam proporcionar análises mais realistas e precisas. O conjunto de dados não possui informações de passageiros (devido à licença), por isso o foco dessa análise foi nos passeios. Caso houvesse essa informação, poderia haver uma análise quantitativa de quantos passageiros casuais poderiam ser convertidos em membros.

Outra informação válida seria relativa aos planos. Ter conhecimento de valor e dos benefícios de cada plano seria importante para possíveis análises de retorno financeiro. Além disso, essas informações poderiam sanar a dúvida sobre limite de tempo dos passeios. Não ficou claro se havia um limite de tempo e os passeios longos existentes no conjunto de dados (acima de 5 horas) seriam erros ou se realmente existe essa possibilidade. Essa informação é mais detalhada no arquivo "R-Markdown_Cyclistic".

1 – Isso é uma suposição, já que estamos analisando o número de passeios e não o número de clientes. Assume-se que muitos passeios equivalem a muitos clientes e não o mesmo cliente realizando passeios várias vezes.

Apêndice A – Detalhamento do Power BI

O arquivo Power BI apresenta 3 páginas, sendo elas:

1. **Geral:** análise sem segmentação de dados, onde são observadas as quantidades de passeio por mês, por tipo de plano e por dia da semana.
2. **Análise dos Planos:** página focada no comparativo entre os planos. Nela é analisada a quantidade de passeios por dia da semana e por mês, com segmentação de dados pelo tipo de plano (membro ou casual).
3. **Tempo de Passeio:** página com foco na análise dos tempos de passeio. Os tempos foram separados em 4 categorias (abaixo de 30 minutos, entre 30 e 60 minutos, entre 1 e 5 horas e acima de 5 horas[1]), para ser observado o padrão de utilização de cada plano, considerando também os dias da semana. Nessa página existem duas segmentações de dados, uma para o tipo de plano e outra para os dias da semana.

Como informado no arquivo de detalhamento "R-Markdown_Cyclistic", o conjunto de dados foi simplificado, excluindo colunas que não influenciam na análise. Por isso, as colunas de identificação do passeio (coluna de Id), tipo de bicicleta e colunas de localização (nome e latitude/longitude das estações de início e fim do passeio) foram suprimidas.

Com essa estratégia, foi possível reduzir o tamanho do arquivo, facilitando a sua importação e manuseio no Power BI, sem perdas de informação pertinentes à análise em questão. Após a importação do conjunto de dados "bikes_data_viz", foram criadas três colunas:

- Dia da Semana_n: coluna que retorna o dia da semana (númerico, sendo 1 o domingo e 7 o sábado), considerando a data informada na coluna Horário de Início. Essa coluna tem o objetivo principal de classificar a coluna Dia da Semana (informada no item abaixo), baseado na ordem numérica (de domingo a sábado)
- Dia da semana: utiliza a informação da coluna anterior, formatada para retornar o nome do dia.
- Tempo de passeio: coluna condicional que classifica o tempo de passeio em 4 categorias (abaixo de 30 minutos, entre 30 e 60 minutos, entre 1 e 5 horas e acima de 5 horas).

Além dessas colunas, foi criado também uma outra tabela, com nome "_medidas" (sem dados), para possibilitar a organização das medidas. Foram criadas 3 medidas:

- **Quantidade de Passeios:** contagem do número de linhas do conjunto de dados, já que cada linha equivale a um passeio.
- **Média de duração:** medida criada para visualização (em um cartão) da média de tempo dos passeios no formato minutos:segundos.
- **Média de duração segundos:** medida complementar ao processo de formatação da média de duração.

1 – Vale a observação que, como as características dos planos não são informadas, optou-se por incluir os tempos de passeios com mais de 5 horas, mesmo sem a certeza de isso ser uma possibilidade, ou de erro nos dados.

O Power BI possui algumas limitações ao trabalhar com a formatação de horas:minutos:segundos. A primeira é que, informações com mais de 24 horas não são contabilizadas, por exemplo, caso o passeio tenha 26 horas, no Power BI seria informado apenas 2 horas. Uma outra limitação é com relação a análises descritivas. Caso seja necessário o cálculo da média de tempo por passeio, essa média não teria a formatação horas:minutos:segundos.

Portanto a formatação foi feita manualmente, através da medidas “Média de duração” e “Média de duração segundos”, considerando o tempo do passeio, em segundos. A média de duração dos passeios é da ordem de minutos (de acordo com análises iniciais feitas em R), portanto, o objetivo dessas medidas é escrever essa média no formato minutos:segundos.

A primeira medida concatena a informação da parte inteira do tempo (em segundos), dividido por 60 (parcela dos minutos) com a informação da parcela dos segundos. Essa segunda informação é feita através da segunda medida. A “Média de duração segundos” utiliza o resto da divisão do tempo por 60 (parcela dos segundos) e, caso esse resto seja inferior a 10 segundos, há a concatenação desse valor com um zero (por exemplo 08). Caso seja superior a 10, não há a necessidade dessa etapa.

Vale destacar que esse processo de concatenação com o zero não é feito para os minutos pois em nenhum momento da análise houve médias abaixo de 10 minutos.